

Cuadro comparativo y matriz de costos

¿Por qué usar Gemini 3.5 Flash-Lite? ⁽¹⁾

La razón principal para elegir dicho modelo es su adecuación a la tarea de Prisma, es decir: capacidad para analizar textos de reclamos, clasificarlos entre dos tratamientos posibles y producir un fundamento breve. No obstante, cabe aclarar que la disponibilidad gratuita facilitó el desarrollo académico, pero es simplemente una razón complementaria. Ahora bien, luego de analizar la ficha del modelo en cuestión, provista por Google y considerando las demandas que implica el procesamiento de reclamos efectuado por PRISMA es posible detallar determinadas razones técnicas en virtud de los cuales este modelo resulta apto para las necesidades de este sistema de gestión, a saber:

Razón de elección del modelo de Gemini	Relación con Prisma
Orientación a tareas de clasificación	Prisma solicita distinguir entre derivación técnica y gestión informativa, siguiendo criterios explícitos.
Capacidad de procesar información textual	El modelo recibe la descripción del reclamo y los antecedentes de mantenimiento para elaborar una recomendación contextualizada.
Diseño orientado a respuestas rápidas	Resulta pertinente para un flujo que debe preparar el ticket destinado a la revisión humana, sin demoras innecesarias en razón de la urgencia que supone este tipo de reclamos.
Eficiencia en costos	La tarea es acotada y requiere una respuesta breve lo cual, ésto fundamenta evaluar un modelo de esta categoría, antes de recurrir a alternativas más costosas.
Disponibilidad mediante API	Permite incorporar el análisis dentro de Make y transferir la respuesta a los nodos posteriores del escenario.

Entonces, la elección del modelo en cuestión se sustenta en la relación entre sus fortalezas y las necesidades concretas de Prisma es decir: clasificación de información textual, rapidez de respuesta, integración mediante API y eficiencia económica. Estas características permiten fundamentar su selección para una tarea delimitada dentro de la automatización y contribuyen al objetivo de brindar una gestión de reclamos más ágil y organizada.

(1) <https://ai.google.dev/gemini-api/docs/models/gemini-3.5-flash-lite?hl=es-419>

Cuadro comparativo y matriz de costos

Modalidad de procesamiento mediante API estándar

Cabe agregar que Prisma utiliza solicitudes estándar a la API de Gemini porque su funcionamiento está organizado alrededor del tratamiento individual de cada reclamo procurando la celeridad en la atención. De hecho, en cada ejecución del escenario 1, el nodo de inteligencia artificial recibe los datos de un ticket y los antecedentes correspondientes, en consecuencia, el nodo aludido analiza esa información y devuelve una recomendación de tratamiento más su fundamento. Esta secuencia requiere disponer del resultado del análisis dentro de la misma ejecución. En consecuencia, la modalidad estándar resulta apropiada ya que permite enviar una solicitud por caso para obtener rápidamente una respuesta a los efectos que sea utilizada en los nodos siguientes, sin necesidad de diferir la obtención de los resultados a través de un trabajo de lotes. PRISMA no supone el procesamiento Batch con motivo de las características intrínsecas de este sistema de gestión de reclamos, es decir que los vecinos (propietarios o locatarios) no pueden aguardar una respuesta en los tiempos que sí son admitidos lotes-batch para otros tipos de procesamientos porque potencialmente los reclamos pueden ser urgencias y su diferimiento pone en riesgo a las personas, a las instalaciones y a los inmuebles involucrados, con los costos que implica y los peligros consecuentes de un retraso en la atención.

Matriz de costos/cuadro comparativo

Previo al desarrollo de la matriz y el cuadro en cuestión, es menester hacer la siguiente aclaración, a saber: el hecho de haber optado por un modelo de IA gratuito (Gemini 3.5 Flash Lite), implica la necesidad de elegir otro modelo de IA alternativo que no sea gratuito y que pueda cumplir con las exigencias que supone una gestión de reclamos en consorcios como la que realiza PRISMA. En tal sentido, el modelo GPT-4.1 mini ⁽²⁾, de OpenAI, es una alternativa paga apta para los requerimientos en cuestión porque en función a sus capacidades, es posible combinar seguimiento de instrucciones, baja latencia y la posibilidad de devolver respuestas con una estructura definida.

Volumen propuesto para el cálculo

Propongo utilizar 100 tickets mensuales como supuesto principal, equivalente a unos tres o cuatro reclamos diarios entre los edificios administrados. Es una hipótesis ilustrativa para dimensionar costos, no una demanda real medida de Prisma.

También podemos mostrar 500 y 1.000 tickets para observar cómo aumenta el gasto. En todos los casos, suponemos una solicitud de IA por ticket, sin reintentos.

(2) <https://developers.openai.com/api/docs/models/gpt-4.1-mini>

Cuadro comparativo y matriz de costos

Estimación de tokens por componente

Componente	Caracteres	Palabras	Tokens aproximados por ticket	Base del cálculo
Instrucciones y formato de respuesta	1.608	231	550	Texto fijo extraído del blueprint, excluyendo las referencias de mapeo
Asunto, descripción y unidad o sector	≈600	≈100	200	Supuesto de un reclamo de extensión moderada
Antecedentes reunidos por Text Aggregator	≈1.800	≈300	600	Supuesto de varios antecedentes breves
Total de entrada	≈4.008	≈631	1.350	Instrucciones más información del caso
Respuesta: tratamiento y fundamento	≈450	≈75	150	Supuesto de una respuesta breve

Estos tokens son una estimación presupuestaria, con una aproximación cercana a tres caracteres por token. No existe una conversión exacta y universal entre palabras y tokens: la cantidad depende del texto y del tokenizador del modelo. Para convertir este presupuesto en una medición, se utilizarían los contadores de consumo de las respuestas de la API.

Tarifas para la matriz

Las tarifas estándar consultadas para GPT-4.1 mini son USD 0,40 por millón de tokens de entrada y USD 1,60 por millón de tokens de salida.

Modelo y modalidad	Entrada por millón de tokens	Salida por millón de tokens
Gemini 3.5 Flash Lite, dentro del acceso gratuito utilizado en Prisma	USD 0	USD 0
GPT-4.1 mini, API estándar sin descuentos	USD 0,40	USD 1,60

Cuadro comparativo y matriz de costos

Costo estimado para 100 tickets mensuales

Componente de GPT-4.1 mini	Tokens totales	Tarifa por millón	Costo
Entrada: 1.350 × 100	135.000	USD 0,40	USD 0,054
Salida: 150 × 100	15.000	USD 1,60	USD 0,024
Total mensual estimado	150.000	—	USD 0,078

La comparación por volumen quedaría así:

Tickets mensuales	Gemini dentro del nivel gratuito ¹	GPT-4.1 mini	Gasto estimado de API evitado con Gemini
100	USD 0	USD 0,078	USD 0,078
500	USD 0	USD 0,390	USD 0,390
1.000	USD 0	USD 0,780	USD 0,780

Valga aclarar que el costo cero para Gemini 3.5 Flash-Lite es condicional a que ese volumen esté cubierto por el acceso gratuito; la tabla no confirma que sus cuotas permitan todos los volúmenes propuestos. Los importes no incluyen impuestos ni reintentos.